
Bond Portfolio Optimization via Deep Reinforcement Learning

B조

금융공학과 23학번 박현서

수학과 23학번 김규리

수학과 23학번 박준희

수학과 23학번 박해인

oo. Contents

Project Objective	01
Data	02
Model Architecture	03
Empirical results	04
Robustness test	05
Academic Contribution	06
Reference	07



Financial DL Final_Project

01 Project Objective

01. Project Objective

01

시장 상황에 따라 채권 자산 비중을 동적으로 조정하는 포트폴리오를 설계

02

금리 곡선과 거시경제 변수의 상호작용을 학습하기 위해 Transformer 기반 Cross-Attention 구조 활용

03

학습된 정책을 바탕으로 시장 환경 변화에 대응하며 채권 포트폴리오 비중을 조정하고 성과를 개선



Financial DL Final_Project

02 Data

02. Data

Bond Portfolio Assets

* Vanguard가 운용하는 채권형 뮤추얼 펀드

ETF의 데이터 기간 한계를 보완하기 위해 Vanguard Mutual Fund를 대체지표로 활용

ETF	VBMFS	Asset class	variable
SHY	VFISX	단기 국채	TR_TREAS_S
IEF	VFITX	중기 국채	TR_TREAS_M
TLT	VUSTX	장기 국채	TR_TREAS_L
LQD	VFSTX	단기 투자등급 회사채	TR_CORP_S
	VFICX	중기 투자등급 회사채	TR_CORP_M
	VWESX	장기 투자등급 회사채	TR_CORP_L
HYG	VWEHX	하이일드 회사채	TR_HY

02. Data

Nelson - Siegel Factor

미국 만기별 국채 금리 : 3M 6M 1Y 2Y 5Y 7Y 10Y 20Y 30Y

Nelson - Siegel

다양한 만기의 국채 금리를 3개의 잠재 요인(Level, Slope, Curvature)으로 요약하여 금리곡선의 형태를 설명하는 대표적인 금리모형

β_1 (Level)	β_2 (Slope)	β_3 (Curvature)
금리곡선의 전반적인 금리 수준	장단기 금리차 및 수익률곡선 기울기	중기 구간의 곡선 형태 및 굴곡

02. Data

Goyal-Welch Data Set (RFS, 2008)

자산수익률 예측에 널리 사용되는 거시경제 예측변수 데이터셋

GW data	Selectiton	Asset class	variable
DP			
EP	이익수익률	log(S&P500 최근 12개월 누적 이익/S&P 500 지수	주식시장 가치평가 지표
BM			
NTIS			
TBL	단기 국채 금리	3개월 만기 미국 국채 금리	통화정책
TMS	기간 스프레드	10년 국채금리와 3개월 국채금리의 차이	경기에 대한 시장 기대
DFY	신용 스프레드	BAA등급 회사채와 AAA등급 회사채의 수익률 차이	신용위험 프리미엄
SVAR	주식시장 변동성	해당 월의 일별 S&P500 수익률의 제곱 합	시장 불확실성 및 위험선호도

02. Data

Additional Macro Variables

- 금융시장 변수만으로 설명하기 어려운 실물경제 및 인플레이션 요인을 보완
- 금융시장 전반의 성과를 반영하기 위해 S&P 500 수익률을 포함



Real Economy
Unemployment rate



Inflation
CPI



Market Sentiment
S&P 500 Index

02. Data

Pipeline

Data	Source	preprocessing	lag	Final Variable
Vanguard Bond Mutual Funds	Yahoo Finance	월말 종가 기준 월간 수익률 계산 후 basis point(bp) 단위로 변환		Asset Return
Reward Variable	Yahoo Finance		lag -1	Reward Asset Return
TMS	GW Dataset	10년 국채금리 - 3개월 국채금리 계산(Montly)		Spread 10Y 3M
DFY	GW Dataset	BAA 회사채 수익률 - AAA 회사채 수익률 계산(Montly)		DFY
EP	GW Dataset	log(최근 12개월 이익 / S&P500 지수) 계산(Montly)		EP
SVAR	GW Dataset	원자료(Montly) 사용		SVAR
TBL	GW Dataset	원자료(Montly) 사용		TBILL
S&P 500 Index	GW Dataset	월간 수익률(Return)로 변환		S&P 500 Return
CPI	FRED	전년동월대비 물가상승률(YoY) 계산	lag 1	CPI YoY
Unrate	FRED	원자료 사용	lag 1	Unrate
Treasury Yields	FRED	월별 미국 국채 수익률(3M~30Y)에 Nelson-Siegel OLS 추정을 적용하여 금리곡선의 $\beta_1, \beta_2, \beta_3$ 요인을 산출		$\beta_1, \beta_2, \beta_3$

Final Dataset : foward fill -> 1993-11 to 2024-12



Financial DL Final_Project

03 Model Architecture

03. Model Architecture

What is Transformer?

수업에서 다룬 FNN · CNN · RNN 대신 **Transformer** 구조를 최종 모델로 채택

01

Limitation of previous models

FNN

시계열 데이터에 부적합

RNN

long-term dependency 문제

02

Self-Attention

Attention으로
거시지표 간, 채권 간
관계를 효과적으로 포착

시점·자산 간 상호작용을
병렬적으로 학습

03

Cross-Attention

거시경제 상태(query)가
자산 표현(key/value)을 참조하여
자산과 거시경제의 관계를 파악

03. Model Architecture


What is Attention?

Encoding = 요약 + 변환, i.e. representation

Query : 지금 찾고 싶은 정보 → Current macroeconomic state

Key : 각 정보의 특징을 나타내는 이름표 → Asset representations

Value : 실제로 가져올 정보 → Asset representations



03. Model Architecture

Model Implementation

```
class PortfolioActor(nn.Module):
    def __init__(self, num_assets=NUM_ASSETS, asset_dim=1,
                  macro_dim=MACRO_DIM, embed_dim=32):
        super().__init__()

        self.a_proj = nn.Linear(asset_dim, embed_dim)
        self.a_tf = nn.TransformerEncoder(
            nn.TransformerEncoderLayer(
                embed_dim, nhead=2, batch_first=True,
                dropout=0.1),
            num_layers=1)

        self.m_proj = nn.Linear(macro_dim, embed_dim)
        self.m_tf = nn.TransformerEncoder(
            nn.TransformerEncoderLayer(
                embed_dim, nhead=2, batch_first=True,
                dropout=0.1),
            num_layers=1)

        self.cross_attn = nn.MultiheadAttention(
            embed_dim, num_heads=2, batch_first=True)
        self.norm = nn.LayerNorm(embed_dim)

        self.mlp_weight = nn.Sequential(
            nn.Linear(embed_dim + 1, 16),
            nn.ReLU(),
            nn.Linear(16, 1)
        )
```

```
def forward(self, a_seq, m_seq, w_prev):
    B, L, N, D_a = a_seq.shape

    a_enc = self.a_tf(
        self.a_proj(
            a_seq.transpose(1, 2).reshape(B*N, L, D_a))
    )[:, -1, :].view(B, N, -1)


    m_enc = self.m_tf(self.m_proj(m_seq))
    m_query = m_enc[:, -1:, :]
    attn_out, _ = self.cross_attn(query=m_query, key=a_enc, value=a_enc)
    attn_out = attn_out.expand(-1, N, -1)
    ctx = self.norm(a_enc + attn_out)

    combined = torch.cat([ctx, w_prev.unsqueeze(-1)], dim=-1)
    w_raw = 2.0 * torch.tanh(self.mlp_weight(combined).squeeze(-1))

    # 기본 포트폴리오 가중치 제약 (레버리지 기초 캡)
    gross = w_raw.abs().sum(dim=-1, keepdim=True).clamp(min=1e-6)
    w = torch.where(gross > 2.0, w_raw * (2.0 / gross), w_raw)
    return w
```

03. Model Architecture

PortfolioActor Architecture



Asset and macro sequences are encoded separately. Cross-attention lets the macro state select relevant asset information;

the final MLP combines contextualized asset features with previous weights to generate constrained portfolio allocations.

03. Model Architecture

Global Variables

NUM_ASSETS

7

채권 자산 수

MACRO_DIM

11

거시·시장 변수 차원

BASE_LR

1e-5

기본 학습률

WARMUP_EPOCHS

30

워밍업 구간

MAX_EPOCHS

100

최대 학습 epoch

PATIENCE

10

Early-stop 인내치

WINDOW_SIZE

240

학습 윈도우 (개월)

TARGET_VOL

0.10

목표 연 변동성 (10%)

03. Model Architecture

Dataset Construction with 12-Month Lookback

T 시점 행동을 결정하는 입력

- 이전 12개월 자산 수익률 sequence
- 이전 12개월 거시경제 sequence
- 이전 포트폴리오 가중치 (w_{prev})



Target Reward

다음 시점 realized asset return으로
포트폴리오 성과(reward)를 계산

Raw Returns 별도 저장

정규화하지 않은 raw returns를 따로 보관해
Volatility 추정에 사용

→ 과거 12개월의 시장·자산 흐름을 함께 입력해 시점 의존 구조를 학습

03. Model Architecture

Training Setup & Objective

Rolling-Window Train / Validation / Test Split

- Test years : 2016 – 2024
- Validation window : previous 24 months
- Training window : fixed rolling window
- Test year is never used in training / validation
- 12-month pre-test history → lookback input only

Look-ahead bias 방지

실제 투자와 유사한 out-of-sample 조건에서 전략 평가 가능

Excess Sharpe Optimization

Objective

Maximize annualized excess Sharpe ratio

Risk Control

실현 변동성 > 목표 변동성 → 익스포저 축소

저변동 구간에서도 레버리지는 늘리지 않음

$$\mathcal{L} = - \frac{\sqrt{12} \cdot \mathbb{E}[R^p - R^f]}{\text{Std}(R^p - R^f)}$$

= - annualized excess Sharpe ratio


03. Architecture

Details — Training Scheme

(a) Rolling-Window Train / Validation / Test



(b) Volatility-Managed Step





Financial DL Final_Project

04 Empirical results

04. Empirical results

Experimental Setup

Mean-Variance Optimization(MVO)을 베이스라인으로, 7개 채권 자산 롱·숏 포트폴리오를 2016-2024 구간에서 평가

BASELINE

MVO

비교 기준 전략

TEST PERIOD

2016-2024

Out-of-sample 9년

ASSETS

7

채권 자산 (롱·숏)

VOL TARGET

10%

변동성 관리 목표

Baseline & 매매 규칙

- **Baseline = MVO**
- 직전 12개월의 기대수익률·공분산 행렬을 추정
- 개별 자산 매매 한도 : **-50% ~ +150%**


데이터

- Goyal-Welch 예측 변수 + FRED 거시지표
- Yahoo Finance 채권형 펀드 가격
- **11개** 거시·금융 지표를 cross-attention 입력으로 사용

04. Empirical results

Performance vs. MVO

Metric	RL Agent	Basic MVO
Cumulative Return	48.52%	7.93%
Annualized Return	4.73%	0.92%
Volatility (ann.)	8.13%	3.38%
Sharpe Ratio	0.580	0.262
Max Drawdown	-19.38%	-15.45%



핵심 결과

RL Agent의 샤프 지수는 **0.580**으로 MVO(0.262) 대비 약 2배.
누적 수익도 48.5% vs 8.0%로 위험조정·성과 모두 Baseline을 상회.


WHAT THE CURVE SHOWS

전 구간 RL이 MVO를 상회 — 9년 내내 누적 부의 격차가 유지·확대
2022 채권 폭락 구간에서도 RL은 방어적 비중 축소로 낙폭을 제한

04. Empirical results

RL Agent Monthly Asset Allocation

월별 7자산 롱숏 비중 — 거시 국면에 따라 레버리지와 방향이 동적으로 변화



기간별 투자비중

2016-19 저금리·완화

7개 채권을 모두 long으로 잡고, 총 100~200%까지 레버리지를 썼다. 금리가 떨어지는 환경에서는 채권 가격이 오르고 이자 수익도 유리하기 때문에 Duration과 신용 위험을 적극적으로 떠안는 전략이다.

2020 COVID-19

평상시 롱을 유지하다가 코로나 패닉이 정점이던 3~4월 무렵에만 회사채와 HY를 단기 short으로 전환해 신용 위험을 회피했고, 연준의 유동성 공급으로 시장이 안정되자 다시 빠르게 롱으로 복귀하였다. 국채는 이 기간에도 long을 유지하며 Duration을 방어했다.

2022 긴축·채권 약세


긴축기에는 여러 달에 걸쳐 자산 전반을 short으로 돌렸다. 그래프에서 0 아래로 크게 내려간 구간이 여기이다. 미국 연준이 급격히 금리를 올리자 채권 가격이 급락했는데, 채권을 숏으로 잡아 가격 하락에 배팅하여 능동적으로 대응했다.

2023-24 정상화

포지션 규모를 줄이고 다시 long으로 복귀하되, HY의 높은 이자 수익 선호했다.

04. Empirical results

Cross-Attention Weights



어텐션 가중치란? 모델(cross-attention)이 의사결정 시 어떤 자산 key에 가장 집중했는지를 보여주는 값. 클수록 해당 자산 표현을 더 많이 참조한다.

연도별 해석

2016-17

파란색 T-Bill(단기 국채) 선이 0.19~0.21로 가장 높이 솟아 있다. 연준이 금리 인상을 시작하던 시기라, 단기 금리에 민감한 자산에 모델이 집중했다.

2020

분홍색 High Yield 선이 0.16 수준으로 급등한다. 코로나로 부도 위험이 커지면서, 위험 채권인 HY가 의사결정의 핵심 변수로 떠올랐다.

2021


다시 T-Bill이 0.18로 올라가고 HY는 0.10으로 떨어진다. 경기 회복과 인플레이션 기대, 연준의 자산매입 축소 전망이 나오면서 단기 금리 구간이 다시 중요해진 것으로 해석된다.

2022-24

모든 선이 0.14 부근으로 수렴한다. 특정 자산에 쏠리지 않고 7개 자산을 고르게 참조하게 됐다는 의미로, 시장 전반을 균형 있게 재평가하는 국면으로 해석된다.

04. Empirical results

Gradient Saliency



그라디언트 맵이란? 포트폴리오 가중치를 각 매크로 변수로 편미분(절댓값)한 민감도. 값이 클수록 그 변수의 변화에 포지션이 더 민감하게 반응한다.

연도별 해석

평시(16·18·21·23·24)

NS 인자가 상위에 위치한다. 특별한 충격이 없을 때는 수익률 곡선의 형태 자체가 포지션 결정의 주된 동인이었음을 의미한다.

2017·2019

전반적으로 색이 매우 어둡다. 시장이 안정적이고 큰 변동이 없던 국면이라, 어떤 매크로 변수에도 포지션이 크게 반응하지 않았다.

2020

unemployment(0.29)와 CPI(0.21) 칸이 노란색으로 가장 강하게 나타난다. 코로나로 인한 고용 충격과 그 이후 인플레이션이 모델의 포지션 결정을 좌우했다는 의미이다.

2022

SVAR(0.18)과 NS 인자가 밝아진다. 연준 긴축으로 변동성과 금리가 출렁이던 국면이라, 모델이 변동성과 금리 충격에 민감하게 반응했음을 보여준다.

04. Empirical results

Key Finding

01

Superior Performance

위험조정 성과(샤프지수 0.58)와 수익 모두 MVO을 크게 상회

02

Adaptive Allocation

COVID-19엔 안전자산 성호, 2022 긴축엔 Duration 슷처럼 국면별 능동 대응

03

Interpretability

Attention과 Gradient 분석을 통해 모델이 위기 국면에는 고용·인플레이션 지표에, 평시에는 수익률 곡선에 반응함을 확인.

모델의 판단 근거가 경제 논리와 일치함을 입증.



Financial DL Final_Project

05 Robustness test

05. Robustness test

Long-only Constraint

- Short position을 허용하지 않기 위해 Softmax를 적용
- 모든 자산 비중이 0 이상이 되도록 제약
- Softmax 출력값에 2를 곱하여 총 투자비중(Gross Exposure)을 200%로 고정

Basic RL Agent

Metric	RL Agent	Basic MVO
Cumulative Return	48.52%	
Annualized Return	4.73%	0.92%
Volatility(ann.)	8.13%	
Sharp Ratio	0.5799	0.262
Max Drawdown	-19.38%	

VS

Long-Only constraint RL Agent

Metric	RL Agent	Basic MVO
Cumulative Return	35.88%	11.89%
Annualized Return	3.86%	1.59%
Volatility(ann.)	9.48%	8.12%
Sharp Ratio	0.4054	0.1932
Max Drawdown	-30.79%	-30.50%

- Long-Only 제약 적용 시 샤프 지수는 0.580 → 0.405로 약 0.17 감소하였으나, 여전히 MVO(0.193)를 크게 상회.
- 숏에 의해 상당한 위험 헷지를 실행하고 있음을 반증

05. Robustness test

Turnover(Gu et al. (2020, RFS))



Turnover(t) =

전체 포트폴리오 거래 비중

$$\sum_{i=1}^7$$

$$\left| \boxed{w_{i,t}} - \underbrace{\frac{w_{i,t-1}(1+r_{i,t})}{1 + \sum_j w_{j,t-1}r_{j,t}}}_{\text{drift}} \right|$$

t시점 리밸런싱 후 i자산 비중

t시점 리밸런싱 직전의 i자산 실제 보유비중

t시점 리밸런싱 시 i자산에서 발생하는 거래 비중



Transaction Cost = Turnover X 10bp

➡ Portfolio Return - Transaction Costs로 Sharp ratio 학습

05. Robustness test

Transaction Cost(10bp) Constraint

Basic RL Agent

Metric	RL Agent	Basic MVO
Cumulative Return	48.52%	7.93%
Annualized Return	4.73%	0.92%
Volatility(ann.)	8.13%	3.38%
Sharp Ratio	0.5799	0.262
Max Drawdown	-19.38%	-15.45%

VS

Transaction Cost Constraint RL Agent

Metric	RL Agent	Basic MVO
Cumulative Return	40.09%	-1.81%
Annualized Return	4.10%	-0.14%
Volatility(ann.)	8.37%	3.44%
Sharp Ratio	0.4876	-0.0473
Max Drawdown	-21.56%	-18.93%
Average Turnover(Monthly)	60.99%	88.28%

- RL Agent의 샤프 지수는 0.488로 MVO(-0.047)를 크게 상회하며, 거래비용 반영 이후에도 우수한 위험조정성과를 유지.
- 누적수익률은 40.1%로 MVO(-1.8%) 대비 크게 높은 성과를 기록.
- 평균 Turnover는 61.0%로 MVO(88.3%)보다 낮아, 거래비용을 고려하여 turnover를 감소하는 방향으로 학습하여 더 높은 성과 달성



Financial DL Final_Project

06 Academic Contribution

06. Academic Contribution



연구 주제의 참신성

- 딥러닝 기반 채권 포트폴리오 최적화 연구는 매우 제한적



방법론적 기여

- Transformer Cross-Attention을 활용한 채권 포트폴리오 최적화
- 기존 정적 자산배분 모형 대비 거시경제-채권 상호작용의 동적 학습



해석가능성 및 경제학적 검증

- Attention Weight와 Gradient Saliency 분석을 통해 AI의 투자 판단 근거를 확인하고, 경제 이론과의 정합성을 검증
- 딥러닝의 블랙박스 문제를 완화

The background is a dark collage. On the left, there's a bar chart with several vertical bars of varying heights. Below it, a portion of a bond certificate is visible, showing the word 'BOND' in large letters, 'JOHNSTOWN, PA.' below it, and 'SERIES' further down. On the right side, there's a faint image of a classical building with columns. In the bottom right corner, there's a line graph with a series of data points connected by lines.

Financial DL FinalProject

07 Reference

07. Reference

1. data

- Welch, I., & Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *The Review of Financial Studies*
- Ludvigson, S. C., & Ng, S. (2006). Macro factors in bond risk premia. NBER Working Paper No. 11703.
- Joslin, S., Pribsch, M., & Singleton, K. J. (2014). Risk premiums in dynamic term structure models with unspanned macro risks. *The Journal of Finance*.
- Campbell, J. Y., & Taksler, G. B. (2003). Equity volatility and corporate bond yields. *The Journal of Finance*.
- Gilchrist, S., & Zakrajšek, E. (2012). Credit spreads and business cycle fluctuations. *American Economic Review*.

2. Learning Procedure

- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical asset pricing via machine learning. *The Review of Financial Studies*

3. Model Architecture

- Moreira, A., & Muir, T. (2017). Volatility-managed portfolios. *The Journal of Finance*
- Sood, S., Papasotiriou, K., Vaiciulis, M., & Balch, T. (2026). Deep reinforcement learning for optimal portfolio allocation: A comparative study with mean-variance optimization. *arXiv*.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)*.



Thank You

B조

금융공학과 23학번 박현서

수학과 23학번 김규리

수학과 23학번 박준희

수학과 23학번 박해인